Lab 4 - GPGPU

Ignacio Scarinci

Características de la PC

Características

- Procesador: Intel i7-6700HQ
- Memoria RAM: 16 GB (2x8GB DDR4-2133)
- NVIDIA GEFORCE GTX950M (MAXWELL)
- S.O. UBUNTU 20.04.2 LTS
- Kernel: 5.8.0-53-generic

Características de la PC

Características de ZX81

- Procesador: Intel Xeon E5-2680 v4 @ 2.40
 GHz
- Memoria RAM: 128 GB
- NVIDIA GEFORCE RTX3070
- S.O. Debian 5.10.40-1
- Kernel: 5.10.0-7-amd64

```
unsigned long PHOTONS:
unsigned int NUM BLOCKS;
unsigned int THREADS POR BLOCK:
sscanf(argv[1], "%lu", &PHOTONS);
sscanf(argv[2], "%iu", &NUM BLOCKS);
sscanf(argv[3], "%iu", &THREADS POR BLOCK);
printf("# Scattering = %8.3f/cm\n", MU S);
printf("# Absorption = %8.3f/cm\n", MU A);
printf("# Photons = %8lu\n#\n", PHOTONS);
const float albedo = MU S / (MU S + MU A);
const float shells per mfp = 1e4 / MICRONS PER SHELL / (MU A + MU S);
unsigned int hilos tot = THREADS POR BLOCK * NUM BLOCKS;
checkCudaCall( cudaMemcpyToSymbol(albedo cd, &albedo, sizeof(float)));
checkCudaCall( cudaMemcpyToSymbol(shells per mfp cd, &shells per mfp, sizeof(float)));
checkCudaCall( cudaMemcpyToSymbol(hilos tot cd, &hilos tot, sizeof(int)));
unsigned long long* fotones simulados;
fotones simulados = 0;
checkCudaCall(cudaMallocManaged(&fotones simulados, sizeof(unsigned long long)));
curandStatePhilox4 32 10 t *devPHILOXStates;
                        hilos tot * sizeof(curandStatePhilox4 32 10 t))):
```


```
double start = wtime();
dim3 dimBlock(THREADS_POR_BLOCK);
dim3 dimGrid(NUM_BLOCKS);
//inicializo el generado de números aleatorios
init_rng<<<dimGrid, dimBlock>>>(devPHILOXStates);
checkCudaCall( cudaDeviceSynchronize() );
```

```
__global__ void init_rng(curandStatePhilox4_32_10_t *state)
{
    int id = threadIdx.x + blockIdx.x * blockDim.x;
    // Cada hilo se inicializa con la misma semilla pero con distinta secuencia clock_t clock();
    long long int clock64();
    curand_init(clock64(), id, 0, &state[id]);
}
```

```
simulador<<<dimGrid,dimBlock>>>(heat, heat2, devPHILOXStates, fotones simulados);
checkCudaCall( cudaDeviceSynchronize() );
 double end = wtime();
 assert(start <= end);</pre>
 double elapsed = end - start;
 printf("# %lf seconds\n", elapsed);
 printf("# %lf K photons per second\n", 1e-3 * PHOTONS / elapsed);
 printf("# Fotones simulados = %llu\n#\n", fotones simulados[0]);
 printf("# Radius\tHeat\n");
 printf("# [microns]\t[W/cm^3]\tError\n");
 float t = 4.0f * M PI * powf(MICRONS PER SHELL, 3.0f) * PHOTONS / 1e12;
 for (unsigned int i = 0; i < SHELLS - 1; ++i) {
    printf("%6.0f\t%12.5f\t%12.5f\n", i * (float)MICRONS PER SHELL,
            heat[i] / t / (i * i + i + 1.0 / 3.0),
            sqrt(heat2[i] - heat[i] * heat[i] / PHOTONS) / t / (i * i + i + 1.0f / 3.0f));
 printf("# extra\t%12.5f\n", heat[SHELLS - 1] / PHOTONS);
return 0;
```


```
qlobal void simulador(float* heat, float* heat2, curandStatePhilox4 32 10 t *state, unsigned long long *fotones simulados)
curandStatePhilox4 32 10 t localState = state[id];
    p.cascaron = shells cd - 1:
 p.weight *= albedo cd;
  atomicAdd(&heat[p.cascaron], (1.0f - albedo cd) * p.weight);
   if(curand uniform(&localState) > 0.1f)
     if(atomicAdd(fotones simulados,lul) < (num fotones cd-hilos tot cd))</pre>
  float xi1, xi2;
     xi1 = 2.0f * curand uniform(&localState) -1.0f;
     xi2 = 2.0f * curand uniform(&localState) -1.0f;
```

GTX 950M




El Mejor resultado se obtuvo con Bloque de 32 y Grid de 60. La velocidad fue de 4965 kfotones/s

RTX 3070




El Mejor resultado se obtuvo con Bloque de 320 y Grid de 10. La velocidad fue de 16440 kfotones/s



2do. Intento


```
__syncthreads();
for(int i=threadIdx.x; i<SHELLS;i+=blockDim.x){
   atomicAdd(&heat[i],heat_b[i]);
   atomicAdd(&heat2[i],heat2_b[i]);
}
__syncthreads();</pre>
```

GTX 950M




El Mejor resultado se obtuvo con Bloque de 64 y Grid de 100. La velocidad fue de 6140 kfotones/s


RTX 3070




El Mejor resultado se obtuvo con Bloque de 192 y Grid de 300. La velocidad fue de 81383 kfotones/s




Roofline



Roofline



Roofline



Todos contra todos

	Lab 1	Lab 2	Lab 3	Lab 4
kfotones/s	282,46	371,51	6982,59	81383,96
Speedup	1	1,32	24,72	288,13

Conclusiones

- Es relativamente fácil trasladar un código de CPU a GPU
- Resulta complicado (al menos al principio) entender y manejar de forma optima los distintos niveles de memoria